

Embedded Systems - Term Project Final Report

Theme: STM32 Real Time Audio Event Recognition

Team Members:

1. B11901137 曾銘慶
2. B11901117 黃遠浩
3. B10505001 謝博仲

GitHub: https://github.com/bch9248/eslab_term_project (可以參考final branch)

1. 動機 - Motivation

- 1.1. 隨著智慧裝置與物聯網的普及，語音辨識已成為重要的人機互動方式。在 STM32 上實現語音辨識，讓裝置直接透過語音指令進行控制，提升操作的便利性與使用體驗。
- 1.2. 傳統語音辨識多依賴雲端運算，容易受到網路延遲與隱私問題影響。利用 STM32 執行邊緣端 (Edge AI) 語音辨識，可實現低成本、低功耗且離線運作的智慧系統，提升即時性與資料安全性。

2. 目標 - Objective

- 2.1. 在 STM32 微控制器上實現即時聲音辨識功能，透過音訊擷取、特徵分析與模型推論等技術，使系統能夠在有限的硬體資源下快速處理聲音訊號，達成即時辨識的效果。
- 2.2. 提高 STM32 對目標聲音的辨識準確率與穩定性，讓系統能在不同環境條件下仍具備較高的辨識成功率。


3. 作法 - Method

3.1. STM32 收音

- 使用 STM32 digital microphone 擷取環境音訊
- 透過 DMA 將音訊資料連續傳入 PCM_Buffer [1024]
- 使用 CMSIS-DSP 對音訊資料進行前處理
- 透過 FFT / 能量分析擷取聲音特徵
- 將原始音訊轉換成較小的 feature vector

3.2. 驗證資料正確性

- 為了確保資料與運算為正確與預期結果，使用 UART 將資料從 STM32 導出，並使用 MATLAB 即時繪圖，確認從麥克風收取到的訊號，有確實經過 FFT 轉換



3.3. 收集訓練資料

- 使用MATLAB收集音訊
- 收集三種音訊事件資料
 - 拍手 (Clap) 一秒音訊*50
 - 彈指 (Snap) 一秒音訊*50
 - 環境雜訊 (Noise) 一秒音訊*50
- 一秒data format是256*16 matrix (256frequency bin, 16 time period)

$$\begin{bmatrix}
 f_{1,1} & f_{1,2} & f_{1,3} & f_{1,4} & f_{1,5} & f_{1,6} & \cdots & f_{1,16} \\
 f_{2,1} & f_{2,2} & f_{2,3} & f_{2,4} & f_{2,5} & f_{2,6} & \cdots & f_{2,16} \\
 f_{3,1} & f_{3,2} & f_{3,3} & f_{3,4} & f_{3,5} & f_{3,6} & \cdots & f_{3,16} \\
 f_{4,1} & f_{4,2} & f_{4,3} & f_{4,4} & f_{4,5} & f_{4,6} & \cdots & f_{4,16} \\
 f_{5,1} & f_{5,2} & f_{5,3} & f_{5,4} & f_{5,5} & f_{5,6} & \cdots & f_{5,16} \\
 f_{6,1} & f_{6,2} & f_{6,3} & f_{6,4} & f_{6,5} & f_{6,6} & \cdots & f_{6,16} \\
 f_{7,1} & f_{7,2} & f_{7,3} & f_{7,4} & f_{7,5} & f_{7,6} & \cdots & f_{7,16} \\
 f_{8,1} & f_{8,2} & f_{8,3} & f_{8,4} & f_{8,5} & f_{8,6} & \cdots & f_{8,16} \\
 f_{9,1} & f_{9,2} & f_{9,3} & f_{9,4} & f_{9,5} & f_{9,6} & \cdots & f_{9,16} \\
 f_{10,1} & f_{10,2} & f_{10,3} & f_{10,4} & f_{10,5} & f_{10,6} & \cdots & f_{10,16} \\
 \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\
 f_{256,1} & f_{256,2} & f_{256,3} & f_{256,4} & f_{256,5} & f_{256,6} & \cdots & f_{256,16}
 \end{bmatrix}$$

3.4. 資料處理

- 我們把1秒*50的data接起來, 形成256*800的data matrix, 再以

sliding window=16, stride=1的setup, 產生一個音訊事件785比長度為1秒的data。

■ Label 1-second data (一秒內有發生一次音訊事件)

- 環境噪音:0
- 拍手:1
- 彈指:2

t1	t2	t3	t4(Clap)	...	t18	t19	t20 (Clap)							
$f_{1,1}$	$f_{1,2}$	$f_{1,3}$	$f_{1,4}$	$f_{1,5}$	$f_{1,6}$	$\cdots$	$f_{1,16}$	$f_{1,17}$	$f_{1,18}$	$f_{1,19}$	$f_{1,20}$	$f_{1,21}$	$\cdots$	$f_{1,800}$
$f_{2,1}$	$f_{2,2}$	$f_{2,3}$	$f_{2,4}$	$f_{2,5}$	$f_{2,6}$	$\cdots$	$f_{2,16}$	$f_{2,17}$	$f_{2,18}$	$f_{2,19}$	$f_{2,20}$	$f_{2,21}$	$\cdots$	$f_{2,800}$
$f_{3,1}$	$f_{3,2}$	$f_{3,3}$	$f_{3,4}$	$f_{3,5}$	$f_{3,6}$	$\cdots$	$f_{3,16}$	$f_{3,17}$	$f_{3,18}$	$f_{3,19}$	$f_{3,20}$	$f_{3,21}$	$\cdots$	$f_{3,800}$
$f_{4,1}$	$f_{4,2}$	$f_{4,3}$	$f_{4,4}$	$f_{4,5}$	$f_{4,6}$	$\cdots$	$f_{4,16}$	$f_{4,17}$	$f_{4,18}$	$f_{4,19}$	$f_{4,20}$	$f_{4,21}$	$\cdots$	$f_{4,800}$
$f_{5,1}$	$f_{5,2}$	$f_{5,3}$	$f_{5,4}$	$f_{5,5}$	$f_{5,6}$	$\cdots$	$f_{5,16}$	$f_{5,17}$	$f_{5,18}$	$f_{5,19}$	$f_{5,20}$	$f_{5,21}$	$\cdots$	$f_{5,800}$
$f_{6,1}$	$f_{6,2}$	$f_{6,3}$	$f_{6,4}$	$f_{6,5}$	$f_{6,6}$	$\cdots$	$f_{6,16}$	$f_{6,17}$	$f_{6,18}$	$f_{6,19}$	$f_{6,20}$	$f_{6,21}$	$\cdots$	$f_{6,800}$
$f_{7,1}$	$f_{7,2}$	$f_{7,3}$	$f_{7,4}$	$f_{7,5}$	$f_{7,6}$	$\cdots$	$f_{7,16}$	$f_{7,17}$	$f_{7,18}$	$f_{7,19}$	$f_{7,20}$	$f_{7,21}$	$\cdots$	$f_{7,800}$
$f_{8,1}$	$f_{8,2}$	$f_{8,3}$	$f_{8,4}$	$f_{8,5}$	$f_{8,6}$	$\cdots$	$f_{8,16}$	$f_{8,17}$	$f_{8,18}$	$f_{8,19}$	$f_{8,20}$	$f_{8,21}$	$\cdots$	$f_{8,800}$
$f_{9,1}$	$f_{9,2}$	$f_{9,3}$	$f_{9,4}$	$f_{9,5}$	$f_{9,6}$	$\cdots$	$f_{9,16}$	$f_{9,17}$	$f_{9,18}$	$f_{9,19}$	$f_{9,20}$	$f_{9,21}$	$\cdots$	$f_{9,800}$
$f_{10,1}$	$f_{10,2}$	$f_{10,3}$	$f_{10,4}$	$f_{10,5}$	$f_{10,6}$	$\cdots$	$f_{10,16}$	$f_{10,17}$	$f_{10,18}$	$f_{10,19}$	$f_{10,20}$	$f_{10,21}$	$\cdots$	$f_{10,800}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
$f_{256,1}$	$f_{256,2}$	$f_{256,3}$	$f_{256,4}$	$f_{256,5}$	$f_{256,6}$	$\cdots$	$f_{256,16}$	$f_{256,17}$	$f_{256,18}$	$f_{256,19}$	$f_{256,20}$	$f_{256,21}$	$\cdots$	$f_{256,800}$

1 second data

3.5. Model Training Hyperparameters

- Sliding window: 16 columns
- Stride: 1 column
- Loss: Sparse categorical cross-entropy
- Learning rate: 1e-4
- Optimizer: Adam
- Batch size: 32
- Epochs: 30
- Model architecture (MLP):
 - Input: 4096 (256*16)
 - Dense layer: 16 units, ReLU
 - Output layer: 3 units, Softmax

3.6. STM32即時顯示prediction

- 我們用STM32上的LED1 and LED2來顯示model prediction:
 - Predict label 0 (環境噪音): 兩個LED都不亮

- Predict label 1 (拍手): LED1亮 (DEMO影片左下角綠燈)
- Predict label 2 (彈指): LED2亮 (DEMO影片右邊中間橘燈)

4. 成果 - Result

4.1. Demo youtube link: https://youtu.be/u0Y_5b8otfo?si=LTV5027042KZNsdo

5. 參考文獻 - Reference

5.1. STM32CubeIDE & CMSIS-RTOS documentation

https://www.st.com/resource/en/user_manual/um1722-developing-applications-on-stm32cube-with-rtos-stmicroelectronics.pdf

5.2. CMSIS-DSP software library documentation

<https://arm-software.github.io/CMSIS-DSP/main/>